

Implementação

O capítulo se inicia com organização e definição do dataset utilizado, sendo um conjunto de 882 imagens classificadas em 4 classes, incêndio, s/incêndio, incêndio noturno e s/incêndio noturno, as imagens passaram por um classificador para extrair as suas características, observando existência de chamas, ambiente do incêndio, período do dia, entre outras. O dataset priorizou imagens de incêndios em seu estado inicial, visto que o intuito do modelo era prever incêndios antes que se agravassem.

Para evitar casos onde não houvessem incêndios serem tidos como um falso positivo, foi necessário alimentar o modelo com imagens sem incêndios e somente nuvens, a fim que o modelo não identificasse-as como fumaça.

Inception-V3

Para o classificador foi utilizada a arquitetura inception-V3, que realiza convoluções 1x1, 3x3, 5x5 na mesma camada seguido de pooling para extração dos descritores, o classificador teve de ser treinado separadamente pois o classificador do Inception-V3 é dedicado a outro grupo de dados. Este modelo selecionado foi o Logistic Regression, que utiliza a regressão logística, fórmula similar à regressão linear porém destinada à classificação

$$p(y = 1|x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n)}}$$

Fórmula regressão logística

Finalizando a seção de implementação, o autor menciona limitações em seu projeto ocasionadas pela falta de verba, como a ausência de um número satisfatório de imagens de incêndios noturnos.

Testes e Avaliação

Neste capítulo, foram mostrados os resultados esperados para cada situação encontrada pelo modelo, e como é tratado na pipeline, por exemplo: caso não seja encontrado um

incêndio no classificador, não é necessário estimar a área do incêndio, visto que será sempre 0 pois é inexistente.

Uma tabela interessante foi mostrada, expondo a diferença na acurácia entre todos os modelos testados para extração de características, com a arquitetura Inception-V3 se provando mais adequada para a situação com 78% de acurácia, e a AlexNet se provando ineficaz com apenas 54%.

Também foi efetuada uma comparação nos modelos de classificação, com o Logistic Regression obtendo 94% de precisão e o método tree obtendo 84%

Houve comparação na escolha entre quantidade de classes, no projeto foram usadas duas classes: com incêndio e sem incêndio. Obtendo 94.1% de precisão em fotos tiradas durante o dia e 94.8% para fotos tiradas à noite, diferente da hipótese de 3 classes (incêndio, incêndio inicial e sem incêndio), que demonstrou uma precisão de 83.6%.